

듀얼 뷰 지도 대조 학습을 이용한 소아 상지 골절 분류 연구

신유민^{1†}, 박정은^{2†}, 강대성^{1*}

¹성신여자대학교 바이오헬스융합학부

²성신여자대학교 AI융합학부

{20231624, 20232647}@sungshin.ac.kr, danniskang@gmail.com

Dual-view Supervised Contrastive Learning for Classification of Pediatric Upper Extremity Fractures

Yumin Shin¹, Jeongeun Park², Daesung Kang^{1*}

School of Bio-Health Convergence, Sungshin Women's University

School of AI Convergence, Sungshin Women's University

{20231624, 20232647}@sungshin.ac.kr, danniskang@gmail.com

요약

소아 골절은 흔하게 발생하지만 골격의 미성숙으로 인해 진단이 어려우며, 이는 임상 현장에서 빈번한 진단 오류로 이어진다. 본 연구는 전후방 투영 영상과 측면 투영 영상을 모두 활용하여 소아 상지 골절을 정확하게 분류하기 위한 듀얼 뷰 지도 대조 학습 기반의 모델을 제안한다. 해당 모델은 지도 대조 손실을 통해 강건한 특징 표현을 학습하고, 이후 전체 네트워크를 미세조정 하는 2단계 프레임워크를 활용한다. 실험 결과, 제안된 모델은 F1-score 0.930와 정밀도 0.930을 달성하여 기존 비교 모델 대비 유의미하게 높은 성능을 보였다. 0.930의 높은 민감도를 바탕으로, 본 모델은 골절 진단 누락률을 최대 7.0%까지 감소시킬 수 있음을 확인하였다. 또한, 지도 대조 학습은 일반적인 자기 지도 학습 방식보다 의료 영상에서 변별력 있는 특징을 더욱 효과적으로 포착하는 것으로 나타났다. 결과적으로 본 모델은 소아 응급실에서 비전문의가 더욱 신뢰할 수 있는 진단을 내릴 수 있도록 돕는 효과적인 임상 의사결정 보조 도구로 활용될 수 있다.

1. 서론

골절은 소아기에 발생하는 가장 흔한 외상 중 하나이다. 터키의 한 통계에 따르면 소아 5명 중 1명이 성인이 되기 전 골절을 경험하는 것으로 보고되었다[1]. 소아 골절은 장기적인 합병증을 유발할 수 있어 정확한 조기진단이 필수적이다. 그러나 임상 현장에서는 여전히 진단의 어려움이 존재하며, 이는 미성숙한 골격을 가진 소아의 특성상 뼈의 성숙도와 골절 단계가 다양하여 방사선 영상 해석이 복잡해지기 때문이다[2].

이 중에서도 상지 골절은 전체 소아 골절의 78.8%를 기록하여 임상적 비중이 높으며[3], 특히 상지 전완부를 구성하는 척골(ulna) 부위의 골절은 전체 진단 누락 사례의 31.3%를 차지하는 대표적인 진단 실패 유형으로 꼽힌다[4]. 또한 진단 정확도는 판독자의 숙련도에 의해 큰 영향을 받으며, 전문의와 전공의 사이의 진단 누락률 차이(7.8% vs 34%)는 임상적 신뢰성을 저해하는 요인이 된다[5]. 따라서, 본 연구에서는 이러한 문제를 완화하기 위해 지도 대조 학습(Supervised Contrastive Learning, SupCon)[6] 기반의 듀얼 뷰(dual-view) 소아 상지 골절 분류 모델을 제안하고 그 효용성을 검증한다.

2. 관련 연구

지도 대조 학습은 레이블 정보를 활용해 배치 내 동일 클래스 샘플들을 포지티브 쌍(positive pair)으로 구성함으로써, 임베딩 공간에서 클래스 내 응집도와 클래스 간 분리도를 극대화한다. 손실 함수는 식 (1)과 같이 정의된다.

$$L_{sup} = \sum_{i \in I} \frac{-1}{|P(i)|} \sum_{p \in P(i)} \log \frac{\exp(\mathbf{z}_i \cdot \mathbf{z}_p / \tau)}{\sum_{a \in A(i)} \exp(\mathbf{z}_i \cdot \mathbf{z}_a / \tau)} \quad (1)$$

이때 i 는 미니배치 내 앵커 샘플의 인덱스, $P(i)$ 는 i 와 동일한 클래스인 양성 샘플의 집합, $A(i)$ 는 i 를 제외한 전체 배치 샘플의 집합, $\mathbf{z}_i$ 는 L_2 정규화된 임베딩 벡터, τ 는 temperature 파라미터를 의미한다[6].

지도 대조 학습법은 의료 영상의 미세한 병변 분류에 효과적이다. 일례로 Chen 등은 피부 병변 분류 시 지도 대조 손실을 적용해 기존 크로스 엔트로피 기반 모델 대비 F1-score를 16% 향상시키며 클래스 불균형 문제 해결 가능성을 입증했다[7]. 본 연구 또한 이러한 2단계 학습 구조를 소아 골절 분류에 적용한다.

소아 골절 분류를 위한 딥러닝 연구도 활발히 진행되고 있다. Janisch 등은 CNN 모델(EfficientNet, ResNet 등)을 활용해 소아 원위 요골 용기 골절(torus fracture) 이진 분류 모델을 제안하였으며, EfficientNet-B4 기준 AUC 98%를 달성해 전문가 수준의 성능을 보여주었다[8]. 그러나 해당 연구는 특정 골절 유형에 국한돼 있으며, 테스트 데이터셋을 분류에 유리한 방식으로 구성함에 따라 실제 임상 성능이 과대평가되었을 가능성이 존재한다. 이에 본 연구는 보다 광범위한 부위의 데이터를 포함하는 PediURF 데이터셋을 사용하여 모델의 일반화 성능을 확보하고자 한다.

3. 연구 방법론

3.1. 모델 아키텍처

본 연구에서는 소아 상지 골절의 분류 성능 향상을 위해 듀얼 뷰 지도 대조 학습 기반의 모델을 제안한다. 그림 1은 제안하는 모델의 전체 구조를 나타낸다. 모델은 각 환자의 전후방 투영 영상과 측면 투영 영상을 입력으로 받아 공유 가중치를 가진 인코더를 통해 각각의 특징 벡터를 추출한다. 이렇게 추출된 두 특징은 크로스 어텐션(cross-attention) 또는 단순 연결(concatenation) 방식을 통해 융합되며, 다층 퍼셉트론(MLP)을 거쳐 단일 골절 클래스로 예측된다.




그림 1. 듀얼 뷰 지도 대조 학습 기반 소아 골절 분류 아키텍처

3.2. 학습 전략: 사전 학습과 미세조정

사전 학습 단계에서는 ImageNet으로 사전 학습된 ResNet-34를 공통 인코더로 사용한다. 두 영상이 모델에 입력되면 인코더를 통해 512차원의 특징 벡터로 변환된다. 이후 투영 헤드(projection head)를 거쳐 128차원의 저차원 임베딩 공간으로 사상되며, L_2 정규화 후 최종적인 전후방 특징 벡터와 측면 특징 벡터가 생성된다. 모델은 이렇게 얻어진 특징들을 바탕으로, 동일한 클래스에 속하거나 동일한 환자로부터 획득한 샘플 쌍은 포지티브(positive)로, 그 외의 쌍은 네거티브(negative)로 설정하여 기존의 자기 지도 학습보다 더 풍부하고 변별력 있는 표현 학습을 수행한다.

미세조정 단계에서는 사전 학습을 마친 인코더의 가중치를 분류기에 이식하여 두 개의 특징 벡터를 추출한다. 추출된 두 벡터는 크로스 어텐션 또는 단순 연결 방식으로 융합되어 MLP에 입력되며, 여러 단계의 선형 및 비선형 변환을 거쳐 최종적으로 하나의 클래스 레이블로 예측된다. 예측 레이블과 실제 타겟 클래스 간의 오차는 크로스 엔트로피 손실함수를 통해 계산되며, 이 손실값을 바탕으로 인코더와 분류기를 포함한 전체 네트워크를 미세조정한다.

4. 실험 방법

4.1. 데이터셋 및 전처리

본 연구에서는 중국 선전(Shenzhen) 어린이 병원에서 수집된 PediURF 데이터셋을 활용하였다. 해당 데이터셋은 총 10,530장의 소아 상지 골절 영상으로 구성되며, 각 환자당 전후방 투영 영상 및 측면 투영 영상이 각각 1장씩 포함된다. 데이터셋의 클래스는 골절 발생 부위에 따라 근위 요척골 골절(Proximal ulna and radius fractures), 골간부 요척골 골절(Midshaft ulna and radius fractures), 원위 요척골 골절(Distal ulna and radius fractures)로 구분되며, 각각 528건, 1,319건, 3,374건의 환자 사례를 가진다. 클래스 간 비율은 약 1:2.3:5.9로 데이터 불균형이 관찰되며, 이는 실제 소아 환자 집단에서의 임상적 골절 빈도를 반영한 결과에 해당한다[2]. 데이터는 누출을 방지하고 모델의 일반화 성능을 확보하기 위해 환자 단위를 기준으로 학습·검증·테스트 세트를 각각 64:16:20의 비율로 분할하였다.

X-ray 투영 영상은 모델 입력 규격에 맞춰 224x224 크기로 조정하였으며, 다음과 같은 데이터 증강을 적용하였다. 가장 먼저 50%의 확률로 좌우 반전 및 상하 반전을 수행하였고, 색상 변형(brightness, contrast 등)도 적용하였다. 마지막으로 모든 영상은 ImageNet의 평균과 표준편차를 기준으로 정규화하였다. 데이터 증강 과정에서 전후방 및 측면 영상의 공간적 일치성을 유지하기 위해, 두 영상에 동일한 무작위 변형 값을 적용하였다.

4.2. 실험 설계 및 파라미터 설정

제안 모델의 성능을 정밀하게 평가하기 위해 ResNet-34 모델을 베이스라인 모델로 두고, SupCon, BYOL[9], SimCLR[10] 등 대표적인 대조 학습 모델과의 비교 실험을 수행하였다. 사전 학습 단계에서는 $\tau = 0.07$ 로 설정한 식 (1)의 L_{sup} 을, 미세조정 단계에서는 크로스 엔트로피를 손실함수로 사용하였다. 또한, 최적화 알고리즘으로 Adam을, 학습률 스케줄러로 Cosine Annealing을 적용하였다. 배치 크기는 64로 설정하였다.

SupCon, BYOL, SimCLR 모델은 인코더의 학습률을 $1e-3$ 으로 설정하여 200 에폭 동안 사전 학습을 진행하였다. 이후 미세조정 단계에서 인코더와 분류기의 학습률을 $(1e-6, 1e-5)$, $(1e-5, 1e-4)$, $(1e-4, 1e-3)$ 으로 단계적으로 증가시키며, 각 모델에 대해 50 에폭 기준 최적 학습률 조합을 선정하였다. 모델의 성능 평가는 정확도(Acc), 정밀도(Pre), 민감도(Sen), F1-score(F1)를 지표로 삼아 다각도에서 분석하였다.

5. 결과

5.1. 성능 비교 및 고찰

표 1은 ResNet-34, BYOL, SimCLR, SupCon 모델의 소아 상지 골절 분류 성능을 요약하여 나타낸 것이다. 실험 결과, SupCon의 크로스 어텐션 모델은 모든 평가 지표에서 가장 우수한 성능을 거두었다. F1-score와 정밀도는 모두 0.930을 기록하였으며, 이는 베이스라인 대비 각각 0.4% 향상된 수치이다. 이는 SupCon 모델이 오검출을 줄임으로써 양성 예측에 대한 신뢰도를 확보하였음을 의미한다.

표 1에서 확인되듯, SupCon 모델은 두 가지 특징 융합 방식 모두에서 최상위 성능을 달성하였다. 특징적 피드백으로, BYOL

모델의 경우 크로스 어텐션 적용 시 단순 연결 대비 성능이 크게 저하되었는데, 이는 BYOL의 사전 학습 특성상 두 뷰 간의 임베딩 유사도가 높아 크로스 어텐션을 통한 상호 정보 추출이 제한되었기 때문으로 추정된다. 또한, 특징 융합 방식에 관계없이 SimCLR 모델이 BYOL 모델 대비 더 높은 성능을 기록하였는데, 이는 포지티브 쌍만을 사용하는 BYOL과 달리 SimCLR은 네거티브 쌍도 함께 사용하여 골절 부위 간 미세한 특징 차이를 더 효과적으로 학습하였기 때문으로 해석된다.

표 1. 소아 상지 골절 분류 성능 비교

학습모델	융합방식	Acc	Pre	Sen	F1
ResNet-34	단순 연결	0.923	0.926	0.923	0.924
	크로스 어텐션	0.926	0.926	0.926	0.926
BYOL	단순 연결	0.915	0.918	0.915	0.915
	크로스 어텐션	0.855	0.855	0.855	0.855
SimCLR	단순 연결	0.922	0.922	0.922	0.922
	크로스 어텐션	0.924	0.925	0.924	0.924
SupCon	단순 연결	0.929	0.929	0.929	0.929
	크로스 어텐션	0.930	0.930	0.930	0.930

그림 2는 각 사전 학습 방법에 따른 t-SNE 임베딩 시각화 결과를 나타낸다. SimCLR는 일부 클러스터가 관찰되나, 세 클래스가 여전히 상당 부분 혼재되어 명확한 경계를 형성하지 못하였다. BYOL은 각 클래스가 임베딩 공간 전반에 걸쳐 무작위로 뒤섞여 클래스 간 구분이 거의 이루어지지 않았다. SupCon은 각 클래스가 독립적인 클러스터를 형성하여 뚜렷한 클래스 간 분리가 존재하였으며, 이는 레이블 정보를 직접 활용하는 지도 대조 학습이 자기 지도 대비 표현 학습에 더욱 효과적임을 시각적으로 뒷받침한다.




그림 2. 학습 기법에 따른 t-SNE 임베딩 시각화. 좌측부터 순서대로 SimCLR(128차원), BYOL(256차원), SupCon(128차원).

5.2. 결론

본 연구에서 제안한 SupCon 모델은 4가지 주요 평가 항목에서 모두 최적의 성능을 입증하였다. 서론에서 언급하였듯, 소아 골절은 비전문가가 진단할 경우 누락률이 최대 34%에 달하며,

전문의와 전공의를 포함한 평균적인 진단 누락 가능성 또한 유의미하게 존재한다[5]. 본 연구의 SupCon 모델은 0.930의 민감도를 달성하였으며, 이는 골절을 놓칠 확률을 최대 7.0% 수준으로 억제할 수 있음을 의미한다.

결론적으로, 본 연구에서 제안한 모델은 임상 현장에서 전문의의 진단을 보조하는 도구로서 유의미한 활용 가능성을 시사한다. 다만, 본 실험에서는 ResNet-34 단일 백본만을 사용하였으며, 배치 크기를 64로 고정하여 사전 학습을 수행하였다는 한계가 있다. 향후 연구에서는 ResNet-50, EfficientNet-B1 등 다양한 백본 모델을 도입하여 제안된 학습 전략의 유효성 검증하고, 배치 크기에 대한 하이퍼파라미터 최적화를 통해 모델의 학습 효율과 판독 정확도를 더욱 정교하게 고도화할 계획이다.

참고문헌

[1] Kamaci S. et al., “Epidemiology of Pediatric Fractures and Effect of Socioeconomic Status on Fracture Incidence in Türkiye: A Nationwide Analysis of 2 Million Fractures”, Journal of Pediatric Orthopaedics, vol. 45, 2025.

[2] Tang S. et al., “A Comprehensive X-ray Dataset for Pediatric Ulna and Radius Fractures Analysis,” Scientific Data, vol. 13, 2026.

[3] Lempesis V. et al., “Time trends in pediatric fracture incidence in Sweden during the period 1950–2006,” Acta Orthopaedica, vol. 88, 2017.

[4] Smith J. E., Tse S., Barrowman N. and Bilal A., “Missed fractures on radiographs in a pediatric emergency department,” Canadian Journal of Emergency Medicine, vol. 18, 2016.

[5] Thammaroj T. et al., “Accuracy and Determinants of Radiographic Diagnosis in Pediatric Hand Fractures,” Cureus, vol. 17, 2025.

[6] Khosla P. et al., “Supervised Contrastive Learning,” Advances in neural information processing systems, 2020.

[7] Chen K, Zhuang D. and Chang J. M., “SuperCon: Supervised contrastive learning for imbalanced skin lesion classification,” arXiv:2202.05685, 2022.

[8] Janisch M. et al., “Pediatric radius torus fractures in x-rays—how computer vision could render lateral projections obsolete,” Frontiers in Pediatrics, vol. 10, 2022.

[9] Grill, J. et al., “Bootstrap your own latent—a new approach to self-supervised learning,” Advances in neural information processing systems, 2020.

[10] Chen, T. et al., “A simple framework for contrastive learning of visual representations,” In International conference on machine learning, 2020.